

Master project

Semantic-Motion —— 面向 Loco-Manipulation 的多粒度语义引擎

1. 项目背景与定位

我们已经构建了一套高机动性的软硬一体化动作采集平台，能够源源不断地生产高质量的 RGB/RGBD 视频流和 3D 姿态数据（Loco-manipulation）。然而，仅有“动作”没有“语言”，数据就无法被 VLA 或者动作生成模型理解和使用。

为这些数据赋予语义灵魂，需要构建一个全自动化的软件 Pipeline，利用多模态大模型（VLM）和生成式大模型（LLM），将我们采集到的多视角视频（第一人称 + 固定机位）转化为结构化、高丰富度的文本指令，从而形成 (Video, Motion, Text) 的完整数据闭环。

2. 技术路线与实施方案

模块 A：基于 VLM 的语义感知 (The Perception Module)

基于视频数据或动作渲染数据，调用 VLM 生成文本描述。既要能描述“在做什么任务”（宏观意图），也要能分析“在怎么动”（微观操作）。

- **任务 1：宏观意图识别 (Macro-Intent)**
 - **输入：** 长视频片段（10s+）。
 - **目标：** 识别任务类型（如“将箱子搬运到桌子上”）和意图。关注长时程的目标导向。
- **任务 2：微观动作解析 (Micro-Instruction)**
 - **输入：** 短视频切片（1s-3s）或关键帧。
 - **目标：** 描述具体的手部-物体交互（HOI）和身体姿态（如“双腿微曲，右手抓取把手，左手保持平衡”）。需包含身体部位细节、接触状态和运动轨迹。

模块 B：基于 LLM 的文本增强 (The Augmentation Module)

VLM 生成的原始文本通常比较生硬或模式化。需要利用 LLM 构建一个重写引擎。

- **功能：** 将一条原始描述扩展为 N 条变体。
- **重写策略：**
 - **句式变换：** 主动/被动语态切换，命令式/描述式切换。
 - **细节注入：** 在不改变语义的前提下，随机加入对环境（“在杂乱的房间里”）、速度（“迅速地”）或风格（“小心翼翼地”）的修饰。
 - **严格约束 LLM 不产生幻觉，确保语义一致性。**

模块 C：自动化清洗与对齐 (The Refinement Module)

由于原始数据可能包含低质量片段，或者 VLM 发生了错误，需要一个过滤机制。

- **低质量动作过滤：**使用3D指标结合VLM对动作质量进行评分，并过滤掉低质量动作
- **语义一致性过滤：**将生成的文本反向输入给 VLM，询问“这段文字是否准确描述了视频内容？”，剔除低置信度样本。

模块 D：基于物理引擎的动作渲染 (The Rendering Module)

针对纯动作捕捉（Motion Capture）数据或仿真数据，VLM 无法直接理解 3D 坐标点阵。本模块旨在搭建一个高保真渲染管线，将“数字信号”转化为 VLM 可感知的“视觉信号”。

- **多视角合成 (Multi-view Synthesis)：**在渲染引擎中设置虚拟相机，模拟真实采集环境。
 - **Egocentric View：**渲染机器人头部/眼部的第一人称视角，关注操作细节。
 - **Fixed View：**渲染第三人称固定机位视角，关注全身姿态与环境关系。
- **场景增强 (Scene Context)：**为动作添加简单的场景上下文（如桌子、障碍物）或使用纯色背景，以辅助 VLM 聚焦于动作本身。